Análisis de encuestas de hogares con R

Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

Análisis de encuestas de hogares con R Módulo 1: Análisis de variables continuas

Andrés Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

CEPAL - Unidad de Estadísticas Sociales

Análisis de encuestas de hogares con R Andrés Gutiérrez,

Ph.D. Stalyn Guerrero, M.Sc.

Lectura de la base

Análisis de encuestas de hogares con R

> Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

Andrés

```
encuesta <- readRDS("../Data/encuesta.rds")</pre>
```

Definir diseño de la muestra con srvyr

Análisis de encuestas de hogares con R

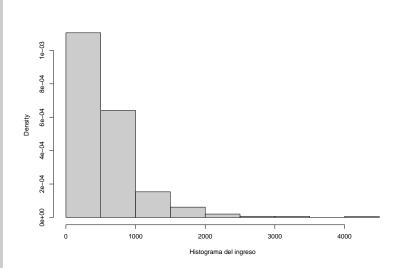
```
options(survey.lonely.psu="adjust")
library(srvyr)
diseno <- encuesta %>%
  as_survey_design(
    strata = Stratum,
    ids = PSU,
    weights = wk,
   nest = T
```

Histograma ponderado para la variable ingreso

```
Análisis de
encuestas de
hogares con R
```

Histograma ponderado para la variable ingreso

Análisis de encuestas de hogares con R



Comparación de histogramas

```
Andrés
Gutiérrez,
Ph.D.
Stalyn
Guerrero,
M.Sc.
```

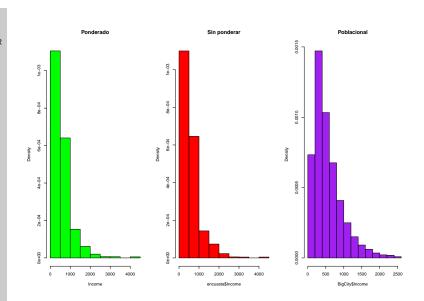
Análisis de

encuestas de

```
data("BigCity", package = "TeachingSampling")
par(mfrow = c(1,3))
svyhist( ~ Income,
  diseno, main = "Ponderado".
  col = "green"
hist(encuesta$Income,
  main = "Sin ponderar",
  col = "red", prob = TRUE
hist( BigCity$Income,
  main = "Poblacional",
  col = "purple", prob = TRUE,
  xlim = c(0, 2500), breaks = 200
```

Comparación de histogramas

Análisis de encuestas de hogares con R



Sub-grupos

Análisis de encuestas de hogares con R

> Andrés Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

Extraer sub-grupos de la encuesta.

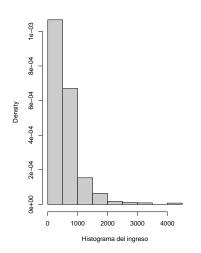
```
sub_Urbano <- diseno %>% filter(Zone == "Urban")
sub_Rural <- diseno %>% filter(Zone == "Rural")
sub_Mujer <- diseno %>% filter(Sex == "Female")
sub_Hombre <- diseno %>% filter(Sex == "Male")
```

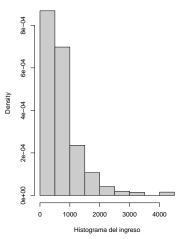
Histograma ponderado en sub-grupos

```
Análisis de
           par(mfrow = c(1,2))
encuestas de
hogares con R
           svyhist(
 Andrés
              ~ Income ,
 Gutiérrez,
  Ph.D.
              subset (sub_Mujer, Age >= 18),
  Stalvn
 Guerrero,
             main = "",
  M Sc
             col = "grey80",
             xlab = "Histograma del ingreso"
           svyhist(
              ~ Income .
              subset (sub_Urbano, Age >= 18),
             main = "",
             col = "grey80",
             xlab = "Histograma del ingreso"
```

Histograma ponderado en sub-grupos

Análisis de encuestas de hogares con R





Boxplot ponderado del ingreso por sub-grupos

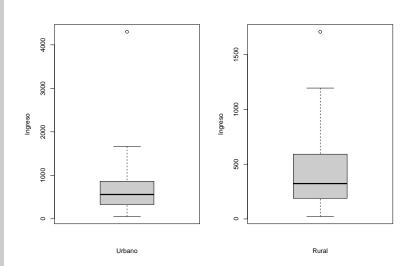
```
encuestas de
hogares con R
Andrés
Gutiérrez,
Ph.D.
Stalyn
Guerrero,
M.Sc.
```

Análisis de

```
par(mfrow = c(1,2))
svyboxplot(
  Income ~1.
  sub Urbano,
  col = "grey80",
  ylab = "Ingreso",
  xlab = "Urbano")
svyboxplot(
  Income ~ 1,
  sub_Rural,
  col = "grey80",
  ylab = "Ingreso",
  xlab = "Rural"
```

Boxplot ponderado del ingreso por sub-grupos

Análisis de encuestas de hogares con R

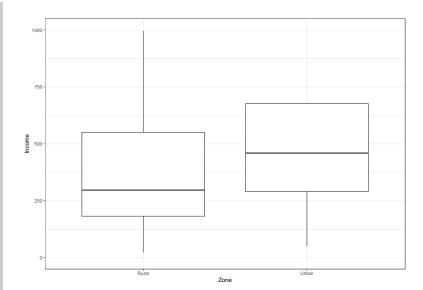


Boxplot ponderado del ingreso por sub-grupos alternativa

```
Análisis de
encuestas de
hogares con R
```

Boxplot ponderado del ingreso por sub-grupos alternativa

Análisis de encuestas de hogares con R



Estimación de totales e intervalos de confianza del ingreso

Análisis de encuestas de hogares con R Andrés Gutiérrez, Ph.D. Stalyn

> Guerrero, M.Sc

svytotal (~Income, diseno, deff=T) %>%
data.frame()

	total	Income	deff
Income	85793667	4778674	11

confint(svytotal (~Income, diseno, deff=T))

	2.5 %	97.5 %
Income	76427637	95159697

Estimación de totales e intervalos de confianza del gasto

Análisis de encuestas de hogares con R Andrés

Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc. svytotal (~Expenditure, diseno, deff=T) %>%
data.frame()

	total	Expenditure	deff
Expenditure	55677504	2604138	10.22

confint(svytotal (~Expenditure, diseno, deff=T))

	2.5 %	97.5 %
Expenditure	50573486	60781522

Estimación de totales por sub-grupos

Análisis de encuestas de hogares con R

Sex	Total	Total_se	Total_low	Total_upp
Female	44153820	2324452	39551172	48756467
Male	41639847	2870194	35956576	47323118
Total ingreso	85793667	4778674	76331414	95255920

Estimación de la media e intervalo de confianza del ingreso

encuestas de hogares con R Andrés Gutiérrez, Ph.D. Stalyn Guerrero,

M Sc

Análisis de

svymean(~Income, diseno, deff=T) %>%
data.frame()

	mean	Income	deff
Income	570.9	28.48	8.821

confint(svymean (~Income, diseno, deff=T))

	2.5 %	97.5 %
Income	515.1	626.8

Estimación de la media e intervalo de confianza del gasto

encuestas de hogares con R Andrés Gutiérrez, Ph.D. Stalyn Guerrero,

M Sc

Análisis de

svymean (~Expenditure, diseno, deff=T) %>%
data.frame()

	mean	Expenditure	deff
Expenditure	370.5	13.29	6.016

confint(svymean (~Expenditure, diseno, deff=T))

	2.5 %	97.5 %
Expenditure	344.5	396.6

Estimación de la media por sub-grupos

Análisis de encuestas de hogares con R

```
diseno %>% group_by(Sex) %>%
  cascade(
    Media = survey_mean(
        Expenditure, level = 0.95,
        vartype = c("se", "ci")),
        .fill = "El gasto medio" ) %>%
  arrange(desc(Sex))
```

Sex	Media	Media_se	Media_low	Media_upp
Male	374.4	16.06	342.6	406.2
Female	367.0	12.34	342.6	391.5
El gasto medio	370.5	13.29	344.2	396.9

Estimación de la media por sub-grupos

Análisis de encuestas de hogares con R

```
diseno %>% group_by(Zone) %>%
  cascade(
    Media = survey_mean(
    Expenditure, level = 0.95,
    vartype = c("se", "ci")),
        .fill = "El gasto medio")%>%
  arrange(desc(Zone))
```

Zone	Media	Media_se	Media_low	Media_upp
Urban	459.6	22.21	415.6	503.6
Rural	273.9	10.26	253.6	294.3
El gasto medio	370.5	13.29	344.2	396.9

Estimación de medias por sub-grupos

Análisis de encuestas de hogares con R

```
diseno %>% group_by(Zone, Sex) %>%
  cascade(
    Media = survey_mean(
        Expenditure, level = 0.95,
        vartype = c("se", "ci")),
        .fill = "El gasto medio") %>%
  arrange(desc(Zone), desc(Sex)) %>%
  data.frame()
```

Zone	Sex	Media	Media_se	Media_low	Media_upp
Urban	Male	469.8	26.96	416.4	523.2
Urban	Female	450.8	20.12	411.0	490.7
Urban	El gasto medio	459.6	22.21	415.6	503.6
Rural	Male	275.3	10.25	255.0	295.6
Rural	Female	272.7	11.61	249.7	295.7
Rural	El gasto medio	273.9	10.26	253.6	294.3
El gasto medio	El gasto medio	370.5	13.29	344.2	396.9

Estimación de la desviación estándar de los ingresos por sub-grupo

```
encuestas de
hogares con R
Andrés
Gutiérrez,
Ph.D.
Stalyn
Guerrero,
M.Sc.
```

Análisis de

```
(tab_sd <- diseno %>% group_by(Zone) %>%
   summarise(Sd = sqrt(
   survey_var(
     Income,
     level = 0.95,
     vartype = c("se", "ci"),
   )
)))
```

Zone	Sd	Sd_se	Sd_low	Sd_upp
Rural	310.3	117.4	262.6	351.6
Urban	581.9	285.0	421.6	706.7

Estimación de la desviación estándar de los ingresos por sub-grupo

```
encuestas de
hogares con R
Andrés
Gutiérrez,
Ph.D.
Stalyn
Guerrero,
M.Sc.
```

Análisis de

```
(tab_sd <- diseno %>% group_by(Zone, Sex) %>%
   summarise(Sd = sqrt(
   survey_var(
     Income,
     level = 0.95,
     vartype = c("se", "ci"),
   )
))) %>% data.frame()
```

Zone	Sex	Sd	Sd_se	Sd_low	Sd_upp
Rural	Female	294.9	111.6	249.6	334.1
Rural	Male	325.8	125.0	274.2	370.2
Urban	Female	568.4	286.5	400.7	696.8
Urban	Male	596.8	288.9	436.8	722.1

Estimación de la mediana para gastos

Análisis de encuestas de hogares con R

```
diseno %>% summarise(Mediana =
  survey_median(
    Expenditure,
    level = 0.95,
    vartype = c("se", "ci"),
    ))
```

Mediana	Mediana_se	Mediana_low	Mediana_upp
298.3	8.825	282.2	317.2

Estimación de la mediana por sub-grupo

Análisis de encuestas de hogares con R

```
diseno %>% group_by(Zone) %>%
  summarise(Mediana =
  survey_median(
    Expenditure,
    level = 0.95,
    vartype = c("se", "ci"),
    ))
```

Zone	Mediana	Mediana_se	Mediana_low	Mediana_upp
Rural	240.7	11.00	214.2	258.3
Urban	380.7	19.84	337.1	416.3

Estimación de la mediana por sub-grupo

Análisis de encuestas de hogares con R

```
diseno %>% group_by(Sex) %>%
  summarise(Mediana =
  survey_median(
    Expenditure,
    level = 0.95,
    vartype = c("se", "ci"),
    ))
```

Sex	Mediana	Mediana_se	Mediana_low	Mediana_upp
Female	299.9	10.499	282.2	323.8
Male	297.3	9.287	277.3	314.1

Estimación de quantile para el gasto

Análisis de encuestas de hogares con R

```
diseno %>%
  summarise(
    Q = survey_quantile(
    Expenditure,
    quantiles = 0.5,
    level = 0.95,
    vartype = c("se", "ci"),
    interval_type = "score"
    ))
```

Q_q50	Q_q50_se	Q_q50_low	Q_q50_upp
298.3	11.96	264.8	312.1

Estimación de quantile para el gasto por sub-grupo

```
Análisis de
encuestas de
hogares con R
```

```
diseno %>% group_by(Sex) %>%
  summarise(
    Q = survey_quantile(
    Expenditure,
    quantiles = 0.25,
    level = 0.95,
    vartype = c("se", "ci"),
    interval_type = "score"
    ))
```

Sex	Q_q25	Q_q25_se	Q_q25_low	Q_q25_upp
Female	209.7	14.91	169.0	228.1
Male	192.5	10.41	163.5	204.7

Estimación de quantile para el gasto por sub-grupo

```
Análisis de
encuestas de
hogares con R
```

```
diseno %>% group_by(Zone) %>%
  summarise(
    Q = survey_quantile(
    Expenditure,
    quantiles = 0.25,
    level = 0.95,
    vartype = c("se", "ci"),
    interval_type = "score"
))
```

Zone	Q_q25	Q_q25_se	Q_q25_low	Q_q25_upp
Rural	159.9	4.641	144.9	163.5
Urban	258.2	9.048	256.0	292.2

Estimación de la razón entre el gasto y el ingreso

Análisis de encuestas de hogares con R

```
diseno %>% summarise(
   Razon = survey_ratio(
      numerator = Expenditure,
      denominator = Income,
      level = 0.95,
   vartype = c("se", "ci")
   ))
```

Razon	Razon_se	Razon_low	Razon_upp
0.649	0.0232	0.6031	0.6949

Estimación de la razón entre hombres y mujeres

Análisis de encuestas de hogares con R

```
diseno %>% summarise(
   Razon = survey_ratio(
      numerator = (Sex == "Female"),
      denominator = (Sex == "Male"),
      level = 0.95,
   vartype = c("se", "ci")
   ))
```

Razon	Razon_se	Razon_low	Razon_upp
1.114	0.0351	1.045	1.184

Estimación de la razón entre hombres y mujeres en la zona rural

Análisis de encuestas de hogares con R

```
sub_Rural %>% summarise(
   Razon = survey_ratio(
      numerator = (Sex == "Female"),
      denominator = (Sex == "Male"),
      level = 0.95,
   vartype = c("se", "ci")
   ))
```

Razon	Razon_se	Razon_low	Razon_upp
1.068	0.0352	0.9975	1.139

Estimación de la razón del gastos y los ingreso entre las mujeres

Análisis de encuestas de hogares con R

```
sub_Mujer %>% summarise(
   Razon = survey_ratio(
      numerator = Expenditure,
      denominator = Income,
      level = 0.95,
   vartype = c("se", "ci")
   ))
```

Razon	Razon_se	Razon_low	Razon_upp
0.6583	0.0199	0.619	0.6976

Estimación de la razón del gasto y los ingresos entre los hombres

Análisis de encuestas de hogares con R

```
sub_Hombre %>% summarise(
   Razon = survey_ratio(
    numerator = Expenditure,
    denominator = Income,
   level = 0.95,
   vartype = c("se", "ci")
))
```

Razon	Razon_se	Razon_low	Razon_upp
0.6391	0.0288	0.5821	0.696

Estimación del índice de GINI

Análisis de encuestas de hogares con R

> Andrés Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

La estimación del índice de GINI se realiza haciendo uso de la librería convey

```
library(convey)
diseno_gini <- convey_prep(diseno)
svygini( ~Income, design = diseno_gini) %>%
  data.frame()
```

	gini	Income
Income	0.4133	0.0187

Estimación del índice de GINI

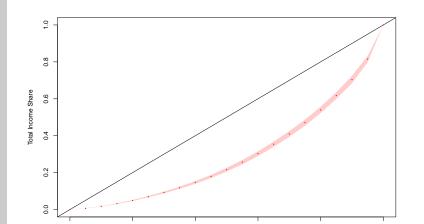
Análisis de encuestas de hogares con R

```
svygini( ~Expenditure, design = diseno_gini) %>%
data.frame()
```

	gini	Expenditure
Expenditure	0.3509	0.0141

Estimación del índice de GINI por sub-grupo

Análisis de encuestas de hogares con R



Pruebas de diferencia medias de los ingresos entre hombres y mujeres

```
Andrés
Gutiérrez,
Ph.D.
Stalyn
Guerrero,
M Sc
```

```
svyttest(Income ~ Sex, diseno)
##
##
   Design-based t-test
##
## data: Income ~ Sex
## t = 1.4, df = 118, p-value = 0.2
## alternative hypothesis: true difference in mean is
## 95 percent confidence interval:
## -12.82 69.39
## sample estimates:
## difference in mean
##
                28,28
```

Pruebas de diferencia medias de los ingresos entre hombres y mujeres en la zona urbana

```
Andrés
Gutiérrez,
Ph.D.
Stalyn
Guerrero,
M.Sc
```

```
svyttest(Income ~ Sex, sub Urbano)
##
##
   Design-based t-test
##
## data: Income ~ Sex
## t = 1.6, df = 63, p-value = 0.1
## alternative hypothesis: true difference in mean is
## 95 percent confidence interval:
## -12.32 101.74
## sample estimates:
## difference in mean
##
                44.71
```

Pruebas de diferencia medias de los ingresos entre hombres y mujeres mayores a 18 años

```
Andrés
Gutiérrez,
Ph.D.
Stalyn
Guerrero,
M.Sc.
```

```
svyttest(Income ~ Sex, diseno %>% filter(Age > 18))
##
##
   Design-based t-test
##
## data: Income ~ Sex
## t = 1.5, df = 118, p-value = 0.1
## alternative hypothesis: true difference in mean is
## 95 percent confidence interval:
## -10.73 82.85
## sample estimates:
## difference in mean
##
                36.06
```

Contrastes

encuestas de hogares con R Andrés Gutiérrez, Ph.D

Análisis de

Ph.D. Stalyn Guerrero, M.Sc.

	Region	Income	se	ci_l	ci_u
Norte	Norte	552.4	55.36	443.9	660.9
Sur	Sur	625.8	62.41	503.5	748.1
Centro	Centro	650.8	61.47	530.3	771.3
Occidente	Occidente	517.0	46.22	426.4	607.6
Oriente	Oriente	541.8	71.66	401.3	682.2

```
# Paso 1: diferencia de estimaciones (Norte - Sur)
461.9124 - 592.2575
```

[1] -130.3

contrastes

Análisis de encuestas de hogares con R

> Andrés Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

Paso 2: error estándar de la diferencia
vcov(prom_region)

	Norte	Sur	Centro	Occidente	Oriente
Norte	3065	0	0	0	0
Sur	0	3894	0	0	0
Centro	0	0	3778	0	0
Occidente	0	0	0	2136	0
Oriente	0	0	0	0	5136

$$sqrt(759.8 + 3755 - 2*0)$$

[1] 67.19

contrastes

```
Análisis de
encuestas de
hogares con R
```

	contrast	diff_NS
diff_NS	-73.41	83.42

Contrastes

Andrés Gutiérrez, Ph.D. Stalyn Guerrero,

M Sc

	contrast	SE
Norte_sur	1178.1	83.42
centro	650.8	61.47
Occidente Oriente	1058.8	85.28

```
sqrt(759.8 + 3755 - 2*0); sqrt(2594);

## [1] 67.19

## [1] 50.93

sqrt(2591 + 1022 - 2*0)

## [1] 60.11
```

Análisis de encuestas de hogares con R

```
(prom_sexo <-
    svyby(~Income, ~Sex, diseno,
        svymean, na.rm=T,covmat = TRUE,
    vartype = c("se", "ci")))</pre>
```

	Sex	Income	se	ci_l	ci_u
Female	Female	557.6	25.83	506.9	608.2
Male	Male	585.8	34.59	518.1	653.6

```
Análisis de
encuestas de
hogares con R
```

	contrast	diff_Sexo
diff_Sexo	-28.28	20.76

Análisis de encuestas de hogares con R

Andrés Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc. vcov(prom_sexo)

	Female	Male
Female	667.2	716.3
Male	716.3	1196.3

```
# Note que el error estandar de la diferencia es igu
sqrt(512.3 + 591.6 - 2*308.8)
```

```
## [1] 22.05
```

Análisis de encuestas de hogares con R

	Region	Income	se	ci_l	С
Norte	Norte	14277323	1507575	11322530	17232
Sur	Sur	16068151	1877989	12387359	19748
Centro	Centro	16483319	2383556	11811634	21155
Occidente	Occidente	16853540	1823807	13278944	20428
Oriente	Oriente	22111335	2833460	16557856	27664

Análisis de encuestas de hogares con R

	contrast	Agregado_NCS
Agregado_NCS	46828792	3388357

Contrastes

Análisis de encuestas de hogares con R

> Andrés Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

	Norte	Sur	Centro	Occidente	Oriente
Norte	2272782099289	0	0	0	0
Sur	0	3526843231468	0	0	0
Centro	0	0	5681340267222	0	0
Occidente	0	0	0	3326270307526	0
Oriente	0	0	0	0	8028493876790

```
sqrt(2805154074898 + 3839259031856 + 7559032807016 )
```

[1] 3768746

Análisis de encuestas de hogares con R

	CatAge	Income	se
0-5	0-5	463.8	28.87
6-15	6-15	511.6	34.88
16-30	16-30	607.3	37.42
31-45	31-45	573.4	26.95
46-60	46-60	763.1	58.97
Más de 60	Más de 60	466.6	31.21

Análisis de encuestas de hogares con R

```
svycontrast(prom_edad,
  list(
  agregado_edad = c(1/6, 1/6, 1/6, 1/6, 1/6, 1/6)
     )) %>% data.frame()
```

	contrast	agregado_edad
agregado_edad	564.3	25.4

Análisis de encuestas de hogares con R

> Andrés Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

vcov(prom_edad)

	0-5	6-15	16-30	31-45	46-60	Más de 60
0-5	833.4	548.4	361.1	262.3	132.7	312.6
6-15	548.4	1216.6	739.7	528.1	565.5	120.1
16-30	361.1	739.7	1399.9	534.9	1564.6	412.5
31-45	262.3	528.1	534.9	726.2	642.3	161.5
46-60	132.7	565.5	1564.6	642.3	3477.7	416.6
Más de 60	312.6	120.1	412.5	161.5	416.6	973.9

[1] 25.65

Análisis de encuestas de hogares con R

	Sex	Income/Expenditure	se.Income/Expenditure	ci_l	ci_
Female	Female	1.519	0.0458	1.429	1.60
Male	Male	1.565	0.0704	1.427	1.70

Análisis de encuestas de hogares con R

	contrast	diff_sexo
diff_sexo	-0.0457	0.0416

Análisis de encuestas de hogares con R

> Andrés Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

vcov(razon_sexo)

	Female	Male
Female	0.0021	0.0027
Male	0.0027	0.0050

$$sqrt(0.0013 + 0.0020 - 2*0.0011)$$

[1] 0.03317

¡Gracias!

Análisis de encuestas de hogares con R

> Andrés Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

> > Email: andres.gutierrez@cepal.org