Análisis de encuestas de hogares con R

Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

Análisis de encuestas de hogares con R Módulo 1: Análisis de variables continuas

Andrés Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

CEPAL - Unidad de Estadísticas Sociales

Análisis de encuestas de hogares con R Andrés Gutiérrez,

Ph.D. Stalyn Guerrero, M.Sc.

Lectura de la base

Análisis de encuestas de hogares con R

```
encuesta <- readRDS("../Data/encuesta_pba.rds")</pre>
```

Definir diseño de la muestra con srvyr

Análisis de encuestas de hogares con R

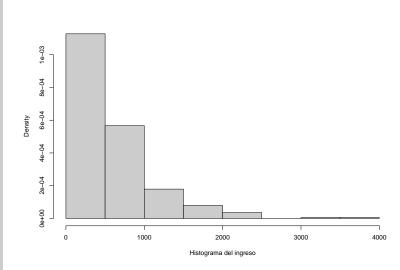
```
options(survey.lonely.psu="adjust")
library(srvyr)
diseno <- encuesta %>%
  as_survey_design(
    strata = Stratum,
    ids = PSU,
    weights = wk,
   nest = T
```

Histograma ponderado para la variable ingreso

```
Análisis de
encuestas de
hogares con R
```

Histograma ponderado para la variable ingreso

Análisis de encuestas de hogares con R



Comparación de histogramas

```
Andrés
Gutiérrez,
Ph.D.
Stalyn
Guerrero,
M.Sc.
```

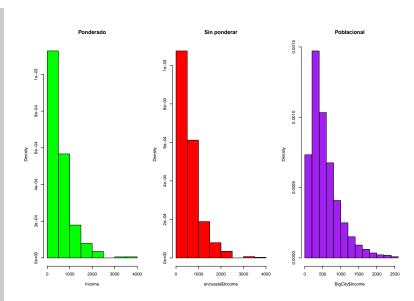
Análisis de

encuestas de

```
data("BigCity", package = "TeachingSampling")
par(mfrow = c(1,3))
svyhist( ~ Income,
  diseno, main = "Ponderado".
  col = "green"
hist(encuesta$Income,
  main = "Sin ponderar",
  col = "red", prob = TRUE
hist( BigCity$Income,
  main = "Poblacional",
  col = "purple", prob = TRUE,
  xlim = c(0, 2500), breaks = 200
```

Comparación de histogramas

Análisis de encuestas de hogares con R



Sub-grupos

Análisis de encuestas de hogares con R

> Andrés Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

Extraer sub-grupos de la encuesta.

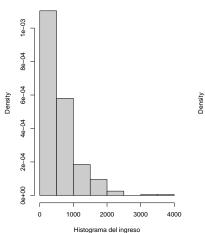
```
sub_Urbano <- diseno %>% filter(Zone == "Urban")
sub_Rural <- diseno %>% filter(Zone == "Rural")
sub_Mujer <- diseno %>% filter(Sex == "Female")
sub_Hombre <- diseno %>% filter(Sex == "Male")
```

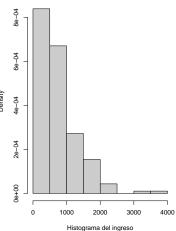
Histograma ponderado en sub-grupos

```
Análisis de
           par(mfrow = c(1,2))
encuestas de
hogares con R
           svyhist(
 Andrés
              ~ Income ,
 Gutiérrez,
  Ph.D.
              subset (sub_Mujer, Age >= 18),
  Stalvn
 Guerrero,
             main = "",
  M Sc
             col = "grey80",
             xlab = "Histograma del ingreso"
           svyhist(
              ~ Income .
              subset (sub_Urbano, Age >= 18),
             main = "",
             col = "grey80",
             xlab = "Histograma del ingreso"
```

Histograma ponderado en sub-grupos

Análisis de encuestas de hogares con R





Boxplot ponderado del ingreso por sub-grupos

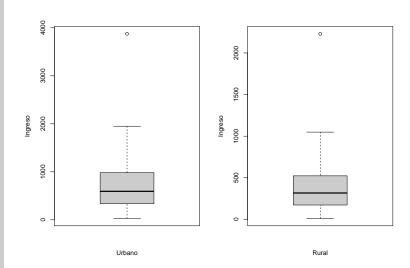
```
encuestas de
hogares con R
Andrés
Gutiérrez,
Ph.D.
Stalyn
Guerrero,
M.Sc.
```

Análisis de

```
par(mfrow = c(1,2))
svyboxplot(
  Income ~1.
  sub Urbano,
  col = "grey80",
  ylab = "Ingreso",
  xlab = "Urbano")
svyboxplot(
  Income ~ 1,
  sub_Rural,
  col = "grey80",
  ylab = "Ingreso",
  xlab = "Rural"
```

Boxplot ponderado del ingreso por sub-grupos

Análisis de encuestas de hogares con R

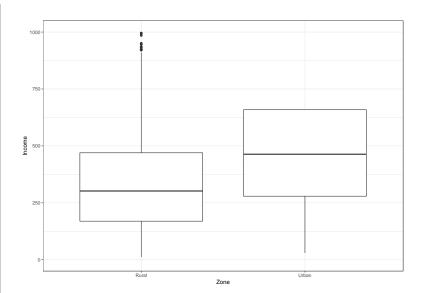


Boxplot ponderado del ingreso por sub-grupos alternativa

```
Análisis de
encuestas de
hogares con R
```

Boxplot ponderado del ingreso por sub-grupos alternativa

Análisis de encuestas de hogares con R



Estimación de totales e intervalos de confianza del ingreso

Análisis de encuestas de hogares con R Andrés

> Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

svytotal (~Income,	diseno,	<pre>deff=T)</pre>	%>%
<pre>data.frame()</pre>			

	total	Income	deff
Income	88683749	4892945	14.2

confint(svytotal (~Income, diseno, deff=T))

	2.5 %	97.5 %
Income	79093753	98273745

Estimación de totales e intervalos de confianza del gasto

Análisis de encuestas de hogares con R Andrés

> Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

svytotal (~Expenditure, diseno, deff=T) %>%
data.frame()

	total	Expenditure	deff
Expenditure	52315200	2252648	14.22

confint(svytotal (~Expenditure, diseno, deff=T))

	2.5 %	97.5 %
Expenditure	47900091	56730309

Estimación de totales por sub-grupos

Análisis de encuestas de hogares con R

Sex	Total	Total_se	Total_low	Total_upp
Female	46918242	2700595	41570793	52265690
Male	41765508	2484707	36845540	46685476
Total ingreso	88683749	4892945	78995230	98372269

Estimación de la media e intervalo de confianza del ingreso

encuestas de hogares con R Andrés Gutiérrez, Ph.D. Stalyn Guerrero, M Sc

Análisis de

svymean(~Income, diseno, deff=T) %>%
data.frame()

	mean	Income	deff
Income	590.2	26.32	9.276

confint(svymean (~Income, diseno, deff=T))

	2.5 %	97.5 %
Income	538.6	641.8

Estimación de la media e intervalo de confianza del gasto

encuestas de hogares con R Andrés Gutiérrez, Ph.D. Stalyn Guerrero,

M Sc

Análisis de

svymean (~Expenditure, diseno, deff=T) %>%
data.frame()

	mean	Expenditure	deff
Expenditure	348.2	10.87	7.473

confint(svymean (~Expenditure, diseno, deff=T))

	2.5 %	97.5 %
Expenditure	326.9	369.4

Estimación de la media por sub-grupos

Análisis de encuestas de hogares con R

```
diseno %>% group_by(Sex) %>%
  cascade(
    Media = survey_mean(
        Expenditure, level = 0.95,
        vartype = c("se", "ci")),
        .fill = "El gasto medio" ) %>%
  arrange(desc(Sex))
```

Sex	Media	Media_se	Media_low	Media_upp
Male	343.2	12.15	319.1	367.2
Female	352.6	10.96	330.9	374.3
El gasto medio	348.2	10.87	326.6	369.7

Estimación de la media por sub-grupos

Análisis de encuestas de hogares con R

```
diseno %>% group_by(Zone) %>%
  cascade(
    Media = survey_mean(
        Expenditure, level = 0.95,
        vartype = c("se", "ci")),
        .fill = "El gasto medio")%>%
  arrange(desc(Zone))
```

Zone	Media	Media_se	Media_low	Media_upp
Urban	441.4	17.014	407.7	475.1
Rural	247.1	9.677	227.9	266.2
El gasto medio	348.2	10.866	326.6	369.7

Estimación de medias por sub-grupos

Análisis de encuestas de hogares con R

```
diseno %>% group_by(Zone, Sex) %>%
  cascade(
    Media = survey_mean(
        Expenditure, level = 0.95,
        vartype = c("se", "ci")),
        .fill = "El gasto medio") %>%
  arrange(desc(Zone), desc(Sex)) %>%
  data.frame()
```

Zone	Sex	Media	Media_se	Media_low	Media_upp
Urban	Male	442.4	19.675	403.4	481.3
Urban	Female	440.6	16.750	407.4	473.7
Urban	El gasto medio	441.4	17.014	407.7	475.1
Rural	Male	240.2	9.966	220.4	259.9
Rural	Female	253.5	10.171	233.4	273.7
Rural	El gasto medio	247.1	9.677	227.9	266.2
El gasto medio	El gasto medio	348.2	10.866	326.6	369.7

Estimación de la desviación estándar de los ingresos por sub-grupo

```
encuestas de
hogares con R
Andrés
Gutiérrez,
Ph.D.
Stalyn
Guerrero,
M.Sc.
```

Análisis de

```
(tab_sd <- diseno %>% group_by(Zone) %>%
   summarise(Sd = sqrt(
   survey_var(
     Income,
     level = 0.95,
     vartype = c("se", "ci"),
   )
)))
```

Zone	Sd	Sd_se	Sd_low	Sd_upp
Rural	372.1	215.2	216.2	479.7
Urban	570.8	248.1	451.6	669.1

Estimación de la desviación estándar de los ingresos por sub-grupo

```
Andrés
Gutiérrez,
Ph.D.
Stalyn
Guerrero,
M.Sc.
```

Análisis de

encuestas de

```
(tab_sd <- diseno %>% group_by(Zone, Sex) %>%
   summarise(Sd = sqrt(
   survey_var(
       Income,
       level = 0.95,
       vartype = c("se", "ci"),
   )
))) %>% data.frame()
```

Zone	Sex	Sd	Sd_se	Sd_low	Sd_upp
Rural	Female	375.6	222.8	206.8	489.3
Rural	Male	368.4	207.2	225.3	469.8
Urban	Female	551.8	241.8	434.5	648.3
Urban	Male	592.3	264.7	460.5	699.7

Estimación de la mediana para gastos

Análisis de encuestas de hogares con R

```
diseno %>% summarise(Mediana =
  survey_median(
    Expenditure,
    level = 0.95,
    vartype = c("se", "ci"),
))
```

Mediana	Mediana_se	Mediana_low	Mediana_upp
289.3	10.9	264.7	307.9

Estimación de la mediana por sub-grupo

Análisis de encuestas de hogares con R

```
diseno %>% group_by(Zone) %>%
  summarise(Mediana =
  survey_median(
    Expenditure,
    level = 0.95,
    vartype = c("se", "ci"),
    ))
```

Zone	Mediana	Mediana_se	Mediana_low	Mediana_upp
Rural	203.8	16.55	179.3	245.7
Urban	385.7	20.76	348.6	431.6

Estimación de la mediana por sub-grupo

Análisis de encuestas de hogares con R

```
diseno %>% group_by(Sex) %>%
  summarise(Mediana =
  survey_median(
    Expenditure,
    level = 0.95,
    vartype = c("se", "ci"),
  ))
```

Sex	Mediana	Mediana_se	Mediana_low	Mediana_upp
Female	298.1	13.43	271.7	324.9
Male	274.3	12.37	252.0	301.0

Estimación de quantile para el gasto

```
Análisis de
encuestas de
hogares con R
```

```
diseno %>%
  summarise(
    Q = survey_quantile(
    Expenditure,
    quantiles = 0.5,
    level = 0.95,
    vartype = c("se", "ci"),
    interval_type = "score"
))
```

Q_q50	Q_q50_se	Q_q50_low	Q_q50_upp
289.3	14.69	240.3	298.5

Estimación de quantile para el gasto por sub-grupo

```
Análisis de
encuestas de
hogares con R
```

```
diseno %>% group_by(Sex) %>%
  summarise(
    Q = survey_quantile(
    Expenditure,
    quantiles = 0.25,
    level = 0.95,
    vartype = c("se", "ci"),
    interval_type = "score"
))
```

Sex	Q_q25	Q_q25_se	Q_q25_low	Q_q25_upp
Female	181	8.545	146.7	180.5
Male	166	7.517	145.7	175.4

Estimación de quantile para el gasto por sub-grupo

```
Análisis de
encuestas de
hogares con R
```

```
diseno %>% group_by(Zone) %>%
  summarise(
    Q = survey_quantile(
    Expenditure,
    quantiles = 0.25,
    level = 0.95,
    vartype = c("se", "ci"),
    interval_type = "score"
    ))
```

Zone	Q_q25	Q_q25_se	Q_q25_low	Q_q25_upp
Rural	140.8	7.118	113.8	142.3
Urban	238.7	13.896	222.6	278.2

Estimación de la razón entre el gasto y el ingreso

Análisis de encuestas de hogares con R

```
diseno %>% summarise(
   Razon = survey_ratio(
      numerator = Expenditure,
      denominator = Income,
      level = 0.95,
   vartype = c("se", "ci")
   ))
```

Razon	Razon_se	Razon_low	Razon_upp
0.5899	0.0194	0.5515	0.6284

Estimación de la razón entre hombres y mujeres

Análisis de encuestas de hogares con R

```
diseno %>% summarise(
   Razon = survey_ratio(
      numerator = (Sex == "Female"),
      denominator = (Sex == "Male"),
      level = 0.95,
   vartype = c("se", "ci")
   ))
```

Razon	Razon_se	Razon_low	Razon_upp
1.114	0.0308	1.053	1.175

Estimación de la razón entre hombres y mujeres en la zona rural

Análisis de encuestas de hogares con R Andrés

```
sub_Rural %>% summarise(
   Razon = survey_ratio(
      numerator = (Sex == "Female"),
      denominator = (Sex == "Male"),
      level = 0.95,
   vartype = c("se", "ci")
))
```

Razon	Razon_se	Razon_low	Razon_upp
1.068	0.0449	0.978	1.158

Estimación de la razón del gastos y los ingreso entre las mujeres

Análisis de encuestas de hogares con R

```
sub_Mujer %>% summarise(
   Razon = survey_ratio(
      numerator = Expenditure,
      denominator = Income,
      level = 0.95,
   vartype = c("se", "ci")
   ))
```

Razon	Razon_se	Razon_low	Razon_upp
0.5952	0.0206	0.5543	0.636

Estimación de la razón del gasto y los ingresos entre los hombres

Análisis de encuestas de hogares con R

```
sub_Hombre %>% summarise(
   Razon = survey_ratio(
    numerator = Expenditure,
    denominator = Income,
   level = 0.95,
   vartype = c("se", "ci")
))
```

Razon	Razon_se	Razon_low	Razon_upp
0.584	0.0195	0.5453	0.6227

Estimación del índice de GINI

Análisis de encuestas de hogares con R

> Andrés Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

La estimación del índice de GINI se realiza haciendo uso de la librería convey

```
library(convey)
diseno_gini <- convey_prep(diseno)
svygini( ~Income, design = diseno_gini) %>%
  data.frame()
```

	gini	Income	
Income	0.4254	0.0132	

Estimación del índice de GINI

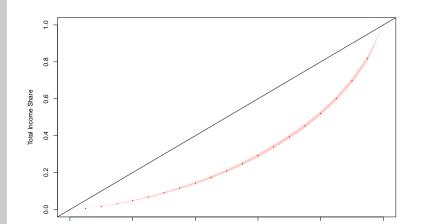
Análisis de encuestas de hogares con R

```
svygini( ~Expenditure, design = diseno_gini) %>%
data.frame()
```

	gini	Expenditure
Expenditure	0.3538	0.0096

Estimación del índice de GINI por sub-grupo

Análisis de encuestas de hogares con R



Pruebas de diferencia medias de los ingresos entre hombres y mujeres

```
Andrés
Gutiérrez,
Ph.D.
Stalyn
Guerrero,
M Sc
```

```
svyttest(Income ~ Sex, diseno)
##
##
   Design-based t-test
##
## data: Income ~ Sex
## t = -0.28, df = 118, p-value = 0.8
## alternative hypothesis: true difference in mean is
## 95 percent confidence interval:
## -39.00 29.28
## sample estimates:
## difference in mean
##
               -4.859
```

Pruebas de diferencia medias de los ingresos entre hombres y mujeres en la zona urbana

```
Andrés
Gutiérrez,
Ph.D.
Stalyn
Guerrero,
M.Sc.
```

```
svyttest(Income ~ Sex, sub Urbano)
##
##
   Design-based t-test
##
## data: Income ~ Sex
## t = 0.42, df = 63, p-value = 0.7
## alternative hypothesis: true difference in mean is
## 95 percent confidence interval:
## -44.12 67.76
## sample estimates:
## difference in mean
##
                11.82
```

Pruebas de diferencia medias de los ingresos entre hombres y mujeres mayores a 18 años

```
Andrés
Gutiérrez,
Ph.D.
Stalyn
Guerrero,
M.Sc
```

```
svyttest(Income ~ Sex, diseno %>% filter(Age > 18))
##
##
   Design-based t-test
##
## data: Income ~ Sex
## t = -0.41, df = 118, p-value = 0.7
## alternative hypothesis: true difference in mean is
## 95 percent confidence interval:
## -44.70 29.31
## sample estimates:
## difference in mean
##
               -7.694
```

Contrastes

Análisis de encuestas de hogares con R Andrés

Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

	Region	Income	se	ci l	ci u
Norte	Norte	487.3	59.48	370.7	603.8
Sur	Sur	656.3	47.51	563.2	749.5
Centro	Centro	671.3	37.56	597.6	744.9
Occidente	Occidente	531.5	57.13	419.5	643.5
Oriente	Oriente	605.8	67.84	472.8	738.8

```
# Paso 1: diferencia de estimaciones (Norte - Sur)
461.9124 - 592.2575
```

[1] -130.3

contrastes

Análisis de encuestas de hogares con R

> Andrés Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

Paso 2: error estándar de la diferencia
vcov(prom_region)

	Norte	Sur	Centro	Occidente	Oriente
Norte	3537	0	0	0	0
Sur	0	2257	0	0	0
Centro	0	0	1410	0	0
Occidente	0	0	0	3264	0
Oriente	0	0	0	0	4603

$$sqrt(759.8 + 3755 - 2*0)$$

[1] 67.19

contrastes

```
Análisis de
encuestas de
hogares con R
```

	contrast	diff_NS
diff_NS	-169.1	76.12

Contrastes

[1] 60.11

Andrés Gutiérrez, Ph.D. Stalyn Guerrero,

M Sc

	contrast	SE
Norte_sur centro	1143.6 671.3	76.12 37.56
Occidente_Oriente	1137.3	88.70

```
sqrt(759.8 + 3755 - 2*0) ; sqrt(2594);

## [1] 67.19

## [1] 50.93

sqrt(2591 + 1022 - 2*0)
```

Análisis de encuestas de hogares con R

```
(prom_sexo <-
    svyby(~Income, ~Sex, diseno,
        svymean, na.rm=T,covmat = TRUE,
    vartype = c("se", "ci")))</pre>
```

	Sex	Income	se	ci_l	ci_u
Female	Female	592.5	27.83	537.9	647.0
Male	Male	587.6	27.53	533.7	641.6

```
Análisis de
encuestas de
hogares con R
```

	contrast	diff_Sexo
diff_Sexo	4.859	17.24

Análisis de encuestas de hogares con R

```
vcov(prom_sexo)
```

	Female	Male
Female	774.7	617.8
Male	617.8	758.1

```
# Note que el error estandar de la diferencia es igu
sqrt(512.3 + 591.6 - 2*308.8)
```

```
## [1] 22.05
```

Análisis de encuestas de hogares con R

	Region	Income	se	ci_l	С
Norte	Norte	12484837	1841598	8875370	16094
Sur	Sur	18394966	1639406	15181790	21608
Centro	Centro	16519417	1597354	13388660	19650
Occidente	Occidente	16712469	2222473	12356502	21068
Oriente	Oriente	24572061	3220380	18260232	30883

Análisis de encuestas de hogares con R

	contrast	Agregado_NCS
Agregado_NCS	47399219	2937801

Contrastes

Análisis de encuestas de hogares con R

> Andrés Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

M	C	C	0 1 1	0
Norte	Sur	Centro	Occidente	Oriento
3391484124672	0	0	0	(
0	2687650650573	0	0	(
0	0	2551540395586	0	(
0	0	0	4939385647690	(
0	0	0	0	10370849850694
	Norte 3391484124672 0 0 0 0	3391484124672 0	3391484124672 0 0 0 2687650650573 0	3391484124672 0 0 0 0 2687650650573 0 0 0 0 2551540395586 0

[1] 3768746

Análisis de encuestas de hogares con R

	CatAge	Income	se
0-5	0-5	570.6	38.15
6-15	6-15	593.5	42.88
16-30	16-30	592.2	29.35
31-45	31-45	616.6	35.41
46-60	46-60	595.3	36.16
Más de 60	Más de 60	555.3	49.50

Análisis de encuestas de hogares con R

```
svycontrast(prom_edad,
  list(
  agregado_edad = c(1/6, 1/6, 1/6, 1/6, 1/6, 1/6)
     )) %>% data.frame()
```

	contrast	agregado_edad
agregado_edad	587.3	27.08

Análisis de encuestas de hogares con R

> Andrés Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

vcov(prom_edad)

	0-5	6-15	16-30	31-45	46-60	Más de 60
0-5	1455.3	575.9	605.4	701.3	500.8	617.9
6-15	575.9	1838.6	618.1	602.0	768.7	637.0
16-30	605.4	618.1	861.3	305.8	727.1	320.7
31-45	701.3	602.0	305.8	1253.9	245.7	1162.9
46-60	500.8	768.7	727.1	245.7	1307.7	226.8
Más de 60	617.9	637.0	320.7	1162.9	226.8	2449.8

[1] 25.65

```
Análisis de
encuestas de
hogares con R
```

-	Sex	Income/Expenditure	se.Income/Expenditure	ci_l	ci_
Female	Female	1.680	0.0583	1.566	1.79
Male	Male	1.712	0.0573	1.600	1.82

Análisis de encuestas de hogares con R

	contrast	diff_sexo
diff_sexo	-0.032	0.0306

Análisis de encuestas de hogares con R

> Andrés Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

vcov(razon_sexo)

	Female	Male
Female	0.0034	0.0029
Male	0.0029	0.0033

```
## [1] 0.03317
```

¡Gracias!

Análisis de encuestas de hogares con R

> Andrés Gutiérrez, Ph.D. Stalyn Guerrero, M.Sc.

> > Email: andres.gutierrez@cepal.org